



Agrupamento Simultâneo de Objetos e Variáveis (co-clustering)

- ▶ São algoritmos que agrupam, simultaneamente, objetos e variáveis com base nas informações de co-ocorrência;
- ▶ Esses algoritmos buscam por blocos de dados (co-clusters) formados por objetos e variáveis cujos elementos são similares;
- ▶ Fornecem uma matriz de dimensão inferior composta por valores representativos de cada bloco.



Agrupamento Simultâneo de Objetos e Variáveis (co-clustering)

- ▶ Algumas vantagens:
 - ▶ São capazes de reduzir a matriz inicial em uma forma mais simples com a mesma estrutura básica;
 - ▶ Exigem menos computação quando comparados com o processo de agrupar objetos e variáveis separadamente;
 - ▶ Podem fornecer resultados mais interessantes que os algoritmos de agrupamento tradicional.



- ▶ Áreas de aplicações: expressão genética, mineração de texto, sistema de recomendação

Métodos particionais exclusivos

Double K-means (dados vetoriais)

- ▶ Fornece uma partição exclusiva (hard, crisp) em K grupos de indivíduos, uma partição exclusiva em H grupos de variáveis e os respectivos representantes (protótipos) dos $K \times H$ blocos de indivíduos e variáveis com base na otimização de uma função objetiva apropriada
- ▶ Seja:
 - ▶ $E = \{e_1, \dots, e_N\}$: o conjunto de objetos, indivíduos, casos, etc
 - ▶ $Y = \{y_1, \dots, y_P\}$: o conjunto de variáveis
 - ▶ $\mathbf{x}_i = (x_{i1}, \dots, x_{ij}, \dots, x_{iP})$: descrição do objeto e_i ($1 \leq i \leq N$)
 - ▶ $\mathbf{X} = (x_{ij})_{\substack{1 \leq i \leq N \\ 1 \leq j \leq P}}$: matrix de dados
 - ▶ g_{kh} : kh -ésimo protótipo do bloco kh
 - ▶ $\mathbf{G} = (g_{kh})_{\substack{1 \leq k \leq K \\ 1 \leq h \leq H}}$: matrix dos protótipos

Métodos particionais exclusivos

Double K-means (dados vetoriais)

- ▶ Função objetivo

- ▶ $W(\mathbf{G}, \mathbf{U}, \mathbf{V}) = \sum_{k=1}^K \sum_{h=1}^H \sum_{i=1}^N \sum_{j=1}^P (u_{ik})(v_{jh})(x_{ij} - g_{kh})^2$

- ▶ Onde

- ▶ $W(\mathbf{G}, \mathbf{U}, \mathbf{V})$: Heterogeneidade total como a soma das heterogeneidades nos kh blocos

- ▶ $\sum_{i=1}^N \sum_{j=1}^P (u_{ik})(v_{jh})(x_{ij} - g_{kh})^2$: Heterogeneidade no bloco kh

- ▶ $\mathbf{U} = (u_{ik})_{\substack{1 \leq i \leq N \\ 1 \leq k \leq K}}$: matrix dos graus de pertinência dos objetos

nos grupos tal que $u_{ik} \in \{0, 1\}$ e $\sum_{k=1}^K u_{ik} = 1$

- ▶ $\mathbf{V} = (v_{jh})_{\substack{1 \leq j \leq P \\ 1 \leq h \leq H}}$: matrix dos graus de pertinência das variáveis

nos grupos tal que $v_{jh} \in \{0, 1\}$ e $\sum_{h=1}^H v_{jh} = 1$

Métodos particionais exclusivos

Double K-means (dados vetoriais)

- ▶ Otimização iterativa: $(\mathbf{G}^{(0)}, \mathbf{U}^{(0)}, \mathbf{V}^{(0)}) \rightarrow (\mathbf{G}^{(1)}, \mathbf{U}^{(0)}, \mathbf{V}^{(0)}) \rightarrow (\mathbf{G}^{(1)}, \mathbf{U}^{(1)}, \mathbf{V}^{(0)}) \rightarrow \dots$
 - ▶ Passo 3: As matrizes $\mathbf{G}$ e $\mathbf{U}$ são fixas:
$$W(\mathbf{V}) = \sum_{j=1}^P \sum_{h=1}^H (v_{jh}) \sum_{i=1}^N \sum_{k=1}^K (u_{ik})(x_{ij} - g_{kh})^2$$
$$\sum_{h=1}^H (v_{jh}) \sum_{i=1}^N \sum_{k=1}^K (u_{ik})(x_{ij} - g_{kh})^2 \rightarrow \min$$
$$v_{jh} = \begin{cases} 1, & \text{se } \sum_{k=1}^K \sum_{i=1}^N (u_{ik})(x_{ij} - g_{kh})^2 = \min_{s=1}^H \sum_{k=1}^K \sum_{i=1}^N (u_{ik})(x_{ij} - g_{ks})^2 \\ 0, & \text{nos outros casos} \end{cases}$$
$$Q_h = \{y_j \in Y : v_{jh} = 1\} \quad (1 \leq h \leq H)$$
 - ▶ Repetir os passos 1, 2 e 3 enquanto houver transferências de objetos e variáveis entre os grupos

Métodos particionais exclusivos

Double K-means (dados vetoriais)

- ▶ O algoritmo é interrompido quando a função objetivo alcança um mínimo local
- ▶ A solução obtida depende da solução inicial, do ponto de partida
- ▶ Executar o Double K-means com diferentes inicializações para obter uma amostra de soluções
- ▶ Entre as soluções obtidas, escolher a melhor, isto é, aquela cuja função objetivo é mínima

Double K-means: Vantagens e desvantagens

► Vantagens

1. Algoritmo simples e rápido
2. Pode lidar eficientemente com grandes conjuntos de dados
3. Exigem menos esforço computacional do que realizar o agrupamento de objetos e variáveis separadamente
4. São capazes de fornecer partições de objetos superiores as fornecidas pelo k-means

► Desvantagens

- Aplicável apenas para dados numéricos
- Requer que o usuário escolha o número apropriado de clusters de objetos (K) e variáveis (H) antecipadamente.
- Os resultados finais obtidos são sensíveis à solução inicial.
- É sensível a valores discrepantes.
- Limitado à descoberta de grupos compactos com formas esféricas
- É sensível a variáveis irrelevantes (ruído)
- Não leva em conta a correlação entre as variáveis
- Não distingue objetos nas fronteiras entre os grupos