

Projeto AM 2026-2

Francisco de A. T. de Carvalho¹

1 Centro de Informatica-CIn/UFPE
Av. Prof. Luiz Freire, s/n -Cidade Universitaria, CEP 50740-540, Recife-PE, Brasil,
fatc@cin.ufpe.br

Questão 1

- Considere a base de dados "spambase" (arquivos anexados com o projeto, <https://archive.ics.uci.edu/dataset/94/spambase>)
 - Considere o algoritmo double k-means (arquivos anexados).
 - Execute o algoritmo double k-means 100 vezes com $K \in \{2, 3, 4\}$ e para cada K com $H \in \{1, \dots, K\}$. Para cada par (K, H) (executado 100 vezes) selecione o melhor resultado segundo a função objetivo.
 - Para cada par (K, H) , calcule a silhueta (Sil). Faça o plot $Sil \times (K, H)$ e escolha o numero de clusters de objetos: $K^* = \arg \max_{(K, H)} Sil((K, H))$.
 - Para a partição de objetos com K^* dada pelo algoritmo double k-means calcule o índice de Rand corrigido. Comente.
 - Para o double k-means e melhor resultado segundo a função objetivo com K^* mostrar: i) a matriz de protótipos dos blocos (**G**); ii) a matrix de confusão da partição de objetos dada pelo algoritmo versus a partição a priori; iv) o plot da função objetivo versus as iterações;

Questão 2

- Considere 2 versões do dataset "spambase". A primeira com a variável resposta original (2 classes a priori). A segunda com a variável resposta com o número de classes igual ao número de clusters de objetos (K^*) obtido na questão 1.
- a) Use validação cruzada estratificada "30 $\times$ 10-folds" para avaliar e comparar os 5 classificadores em cada versão de spambase: i) bayesiano gaussiano, ii) bayesiano baseado em k-vizinhos, iii) bayesiano baseado na janela de Parzen, iv) regressão logística, v) usando a regra do voto majoritário a partir dos 4 primeiros classificadores. Quando necessario, faça validação cruzada 5-folds nos 9 folds restantes para fazer ajuste de hiper-parametros e depois treine o modelo novamente com o conjunto aprendizagem de 9-folds usando os valores selecionados para os hiper-parametros. Use amostragem estratificada.
- b) Obtenha uma estimativa pontual e um intervalo de confiança para cada metrica de avaliação do classificadores (Taxa de erro, precisão, cobertura, F-measure);
- c) Usar o Friedman test (teste não parametrico) para comparar os classificadores, e o pós teste (Nemenyi test), usando cada uma das métricas
- d) Para a metrica de avaliação F-measure, plot a curva de aprendizagem para os 5 classificadores. Mais precisamente, considere conjuntos de treinamento e teste de (5%, 95%) a (95%, 5%) do conjunto original de treinamento, com passo de 5% (usando amostragem estratificada). Para cada par de conjuntos de treinamento e teste, compute as metricas de avaliação tanto no conjunto de treinamento como no conjunto de teste. Comente.

Questão 2

- Considere os seguintes classificadores:

- i) Classificador bayesiano com a seguinte regra de decisão: afetar o exemplo $\mathbf{x}_k$ à classe ω_l ($1 \leq l \leq c$) se $P(\omega_l|\mathbf{x}_k) = \max_{i=1}^{Kc} P(\omega_i|\mathbf{x}_k)$ com

$$P(\omega_i|\mathbf{x}_k) = \frac{p(\mathbf{x}_k|\omega_i)P(\omega_i)}{\sum_{r=1}^{K^*} p(\mathbf{x}_k|\omega_r)P(\omega_r)}, \text{ onde } c \text{ é o número de classes}$$

- a) Use a **estimativa de máxima verossimilhança** para $P(\omega_i)$
- b) Para cada classe ω_i ($1 \leq i \leq c$) use a seguinte estimativa de máxima verossimilhança de $p(\mathbf{x}_k|\omega_i) = p(\mathbf{x}_k|\omega_i, \theta_i)$, supondo uma normal multivariada:

$$p(\mathbf{x}_k|\omega_i, \theta_i) = (2\pi)^{-\frac{d}{2}} (|\hat{\Sigma}_i^{-1}|)^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_k - \hat{\mu}_i)^\top \hat{\Sigma}_i^{-1} (\mathbf{x}_k - \hat{\mu}_i) \right\},$$

onde

$\hat{\Sigma}_i$ eh a estimativa de MV de Σ_i ; $\hat{\mu}_i$ eh a estimativa de MV de μ_i

- ii) Classificador bayesiano baseado em k-vizinhos considerando as distâncias Euclidiana, City-Block e Chebishev para definir a vizinhança. Use validação cruzada para fixar o o número de vizinhos k e a distância.
- iii) Classificador bayesiano baseado em janela de parzen com o kernel multivariado produto. Use validação cruzada para fixar a janela h . Use o kernel gaussiano univariado.
- iv) Classificador baseado em regressão logística usando validação cruzada para fixar os hiper-parâmetros.
- v) Treine um classificador baseado na regra do voto majoritário a partir dos classificadores bayesiano, k-vizinhos, janela de parzen, e regressão logística, .

Observações Finais

- No Relatório deve estar bem claro como foram organizados os experimentos de tal forma a realizar corretamente a avaliação dos modelos e a comparação entre os mesmos. Fornecer também uma descrição sucinta dos dados. No relatório mostrar os detalhes da obtenção dos hiper-parâmetros do modelo, se houver.
- Data de apresentação e entrega do projeto: **QUARTA-FEIRA 18/11/2026**.
- Colocar no **google classroom**: o programa fonte, o executável (se houver), os slides da apresentação e o relatório do projeto
- NÃO COLOCAR NO **google classroom** ARQUIVO ZIP: COLOCAR OS ARQUIVOS INDIVIDUAIS
- Tempo de apresentação: **10 minutos** para cada equipe (rigoroso), incluindo discussão.
- A **PRESENÇA** e **PARTICIPACAO** de todos os membros de cada equipe é **OBRIGATORIA** durante a apresentação;
- As apresentações serão realizadas segundo a numeração das equipes: **primeiro a equipe 01, seguida da equipe 02 até a equipe 11.**